

Control basado en pasividad con aprendizaje estructurado informado por física para manipuladores robóticos

Propuesta de tesis de Maestría

Alumno: José Aarón Barbosa Mercado

Asesores: Dr. Wen Yu Liu, Dr. Fernando Castaños Luna

Departamento de Control Automático, CINVESTAV-IPN

1 Motivación y planteamiento del problema

Los manipuladores robóticos son sistemas dinámicos no lineales sujetos a incertidumbres paramétricas, dinámicas no modeladas, fricción, perturbaciones externas y variaciones de carga. Su estructura Euler–Lagrange permite construir funciones de almacenamiento asociadas a la energía mecánica y diseñar controladores cuya estabilidad se demuestra mediante argumentos de pasividad. El desempeño de estos esquemas, sin embargo, depende críticamente de la calidad del modelo nominal: ante errores de modelado importantes, la compensación por prealimentación resulta insuficiente.

Existen dos respuestas clásicas a este problema, ambas con limitaciones bien conocidas. El control adaptable (Slotine–Li) garantiza convergencia del error de seguimiento, pero exige que la incertidumbre sea *lineal en los parámetros* respecto de un regresor conocido; efectos como la fricción de Stribeck, la flexibilidad de las transmisiones o el *backlash* no admiten esa parametrización. El control por modos deslizantes garantiza robustez frente a incertidumbre acotada arbitraria, pero las ganancias deben dimensionarse para el *peor caso* de la incertidumbre total, lo cual induce castaño, elevado esfuerzo de control y amplificación del ruido de medición.

La presente propuesta parte de la observación de que estas dos limitaciones son complementarias. Si un módulo de aprendizaje *estructurado* captura la parte sistemática y repetible de la incertidumbre, el controlador robusto ya no debe enfrentar la incertidumbre total sino únicamente un residuo de magnitud considerablemente menor, lo que permite reducir las ganancias del modo deslizante. El problema central de la investigación es, entonces, doble:

- (P1) **Compatibilidad estructural.** Una compensación aprendida arbitraria modifica el balance energético del lazo cerrado y puede destruir las propiedades de pasividad empleadas para demostrar estabilidad. ¿Bajo qué restricciones de parametrización de la red se preserva la estructura pasiva del sistema en lazo cerrado?
- (P2) **Cuantificación del beneficio.** ¿Es posible establecer una relación explícita entre la calidad de la aproximación neuronal y las ganancias mínimas admisibles del algoritmo robusto, de modo que la contribución del aprendizaje sea cuantificable y no meramente empírica?

1.1 Formulación

Considérese un manipulador rígido de n grados de libertad,

$$M(q)\ddot{q} + C(q, \dot{q})\dot{q} + g(q) + F(\dot{q}) + \tau_d(t) = \tau, \quad (1)$$

con $q \in \mathbb{R}^n$ las coordenadas articulares, $M(q)$ la matriz de inercia, $C(q, \dot{q})\dot{q}$ los términos de Coriolis y centrífugos, $g(q)$ el par gravitacional, $F(\dot{q})$ la fricción y $\tau_d(t)$ perturbaciones externas. El modelo satisface las propiedades estructurales

$$\lambda_m I \preceq M(q) \preceq \lambda_M I, \quad 0 < \lambda_m \leq \lambda_M < \infty, \quad (2)$$

$$x^\top (\dot{M}(q) - 2C(q, \dot{q}))x = 0, \quad \forall x \in \mathbb{R}^n, \quad (3)$$

$$\dot{q}^\top F(\dot{q}) \geq 0. \quad (4)$$

La propiedad (3) es la que hace pasivo el mapeo $\tau \mapsto \dot{q}$ con función de almacenamiento igual a la energía total, y es también la que debe preservarse al introducir el módulo de aprendizaje.

Sea $q_d(t)$ una trayectoria deseada de clase C^2 y acotada. Se definen

$$e = q - q_d, \quad \dot{q}_r = \dot{q}_d - \Lambda e, \quad s = \dot{q} - \dot{q}_r = \dot{e} + \Lambda e, \quad \Lambda = \Lambda^\top \succ 0. \quad (5)$$

La variable s tiene grado relativo uno respecto de τ , lo cual es esencial: permite aplicar un algoritmo de segundo orden que produce una señal de control *continua*.

Con un modelo nominal $(\hat{M}, \hat{C}, \hat{g})$, el controlador propuesto tiene la estructura

$$\tau = \underbrace{\hat{M}(q)\ddot{q}_r + \hat{C}(q, \dot{q})\dot{q}_r + \hat{g}(q) - K_D s}_{\tau_{\text{pb}}c} + \underbrace{\hat{\Delta}_\theta(q, \dot{q}, \dot{q}_r, \ddot{q}_r)}_{\tau_\ell} + \underbrace{\tau_{\text{sta}}}_{\text{acción robusta}}, \quad (6)$$

donde $K_D = K_D^\top \succ 0$. Sustituyendo (6) en (1) se obtiene la dinámica del error

$$M(q)\dot{s} = -C(q, \dot{q})s - K_D s - \tilde{\Delta} + \tau_{\text{sta}}, \quad \tilde{\Delta} := \Delta - \hat{\Delta}_\theta, \quad (7)$$

con la incertidumbre total

$$\Delta = \tilde{M}(q)\ddot{q}_r + \tilde{C}(q, \dot{q})\dot{q}_r + \tilde{g}(q) + F(\dot{q}) + \tau_d(t), \quad (\tilde{\cdot}) = (\cdot) - (\hat{\cdot}). \quad (8)$$

Observación 1. *La elección de expresar Δ en términos de $\dot{q}_r$ y $\ddot{q}_r$ — y no de $\dot{q}$ y $\ddot{q}$ — es deliberada: Δ no depende de la aceleración medida, sino únicamente de señales conocidas y del estado. Esto es indispensable tanto para la implementación como para la generación de datos de entrenamiento.*

1.2 Descomposición estructurada del residuo

Una contribución conceptual de la propuesta es reconocer que Δ *no* es íntegramente de tipo Euler-Lagrange, y que sólo una parte admite un aprendizaje con garantías de pasividad. Se propone la descomposición

$$\Delta = \underbrace{\Delta_{\text{el}}}_{\text{estructura EL}} + \underbrace{\Delta_{\text{dis}}}_{\text{disipativa}} + \underbrace{\Delta_{\text{ext}}}_{\text{no estructurada}}, \quad (9)$$

donde $\Delta_{\text{el}} = \tilde{M}\ddot{q}_r + \tilde{C}\dot{q}_r + \tilde{g}$ conserva la estructura lagrangiana, $\Delta_{\text{dis}} = F(\dot{q})$ satisface (4) y por tanto *contribuye* a la disipación, y $\Delta_{\text{ext}} = \tau_d(t)$ carece de estructura explorable. El módulo de aprendizaje se dirige a los dos primeros términos; el tercero queda necesariamente a cargo de la acción robusta. Esta separación delimita con precisión qué puede y qué no puede aportar el aprendizaje, y evita la afirmación — frecuente en la literatura y no sostenible — de que una red neuronal puede sustituir a la robustez.

2 Hipótesis

Si el módulo de aprendizaje se parametriza de modo que reproduzca por construcción las propiedades estructurales (2)–(4) del sistema, entonces (i) el lazo cerrado conserva las propiedades de pasividad del controlador nominal, y (ii) la cota de Lipschitz del residuo no compensado admite un certificado explícito que se traduce en una reducción cuantificable de las ganancias mínimas admisibles del algoritmo robusto, sin pérdida de las garantías de convergencia en tiempo finito.

3 Objetivos

Objetivo general

Desarrollar y analizar una arquitectura de control para manipuladores robóticos que integre control basado en pasividad, aprendizaje estructurado informado por física y una acción robusta por modos deslizantes de segundo orden, estableciendo condiciones formales de estabilidad, de preservación de las propiedades energéticas y de convergencia en tiempo finito del residuo de compensación, así como una caracterización cuantitativa del beneficio aportado por el aprendizaje.

Objetivos específicos

1. Diseñar el controlador nominal basado en pasividad (6) y desarrollar su análisis de estabilidad, caracterizando el mapeo pasivo $\tilde{\Delta} \mapsto s$ y su índice de disipación.
2. Formular un módulo de aprendizaje cuya parametrización imponga *por construcción* — y no mediante penalizaciones en la función de costo — la simetría y positividad de la inercia estimada, la antisimetría de $\hat{M}_\theta - 2\hat{C}_\theta$, el carácter gradiente del término gravitacional y la monotonía del término de fricción.
3. Formular el problema de entrenamiento en una forma *libre de aceleración*, basada en la versión filtrada o integral de (1), y definir el protocolo de excitación persistente para la recolección de datos.
4. Demostrar que la incorporación del módulo aprendido al lazo nominal preserva la pasividad de salida estricta, y garantizar la acotación uniforme de $\hat{\Delta}_\theta$ mediante saturación certificada, de modo que un modelo mal entrenado degrade el desempeño sin comprometer la estabilidad.
5. Diseñar la acción robusta Super-Twisting sobre el residuo $\tilde{\Delta}$, abordando explícitamente el acoplamiento inducido por $M^{-1}(q)$ mediante una formulación multivariable o mediante cotas de desacoplamiento derivadas de (2).
6. Establecer una cota de Lipschitz $\|\frac{d}{dt}\tilde{\Delta}\| \leq L_\theta$ certificada a partir de la parametrización de la red (normalización espectral), y derivar la relación explícita $(\delta_\theta, L_\theta) \mapsto (k_1^{\min}, k_2^{\min})$ entre calidad de aproximación y ganancias mínimas admisibles.
7. Caracterizar el beneficio del aprendizaje en las métricas donde éste es teóricamente sostenible: magnitud de las ganancias, esfuerzo y variación total del control, duración de la fase de alcance y precisión de deslizamiento real bajo muestreo.
8. Validar experimentalmente la estrategia en una plataforma robótica, comparando el controlador nominal, el controlador con compensación aprendida, el controlador nominal con STA de ganancia completa y la arquitectura completa.

4 Metodología

4.1 Módulo de aprendizaje estructurado

A diferencia de una red *physics-informed* en el sentido de Raissi et al., donde el conocimiento físico se introduce como penalización del residuo de una EDP en la función de costo, aquí se propone imponer la estructura en la *arquitectura* misma, siguiendo la línea de las redes lagrangianas profundas. Se parametriza

$$\hat{\Delta}_\theta = \hat{M}_\theta(q) \ddot{q}_r + \hat{C}_\theta(q, \dot{q}) \dot{q}_r + \nabla_q \hat{U}_\theta(q) + \hat{D}_\theta(\dot{q}) \dot{q}, \quad (10)$$

con las siguientes construcciones:

- $\hat{M}_\theta(q) = L_\theta(q) L_\theta^\top(q) + \epsilon I$, con L_θ triangular inferior de diagonal positiva. Esto garantiza $\hat{M}_\theta = \hat{M}_\theta^\top \succ 0$ de manera automática.
- $\hat{C}_\theta$ se obtiene de $\hat{M}_\theta$ mediante los símbolos de Christoffel, lo que hace que $\dot{\hat{M}}_\theta - 2\hat{C}_\theta$ sea anti-simétrica *por construcción*, preservando (3).
- El término gravitacional se obtiene como gradiente de un potencial escalar aprendido $\hat{U}_\theta(q)$, lo que garantiza su carácter conservativo.
- $\hat{D}_\theta(\dot{q}) \succeq 0$ se parametriza con pesos no negativos y activaciones monótonas, de modo que $\dot{q}^\top \hat{D}_\theta(\dot{q}) \dot{q} \geq 0$, respetando (4).
- La salida de (10) se satura en una cota $\bar{\Delta}$ obtenida de las especificaciones físicas del manipulador.

4.2 Entrenamiento libre de aceleración

El residuo Δ no es medible directamente, pues involucraría $\ddot{q}$. Aplicando el filtro estable de primer orden $\lambda/(p + \lambda)$ a (1), o bien integrando sobre una ventana $[t - T, t]$ e integrando por partes el término inercial mediante (3), se obtiene una expresión equivalente que involucra únicamente q , $\dot{q}$ y τ medidos. El costo de entrenamiento toma la forma

$$J(\theta) = \sum_k \|\mathcal{F}\{\Delta\}_k - \mathcal{F}\{\hat{\Delta}_\theta\}_k\|^2 + \gamma \mathcal{R}(\theta), \quad (11)$$

donde $\mathcal{F}\{\cdot\}$ denota el operador de filtrado y $\mathcal{R}$ un regularizador que incluye la normalización espectral de cada capa. Los datos se recolectarán con trayectorias de excitación persistente diseñadas mediante series de Fourier finitas, con partición independiente de entrenamiento, validación y prueba.

4.3 Acción robusta y condición de ganancias

Se emplea el algoritmo Super-Twisting sobre la variable s :

$$\tau_{\text{sta}} = -K_1 [s]^{1/2} + v, \quad \dot{v} = -K_2 [s]^0, \quad [x]^p := |x|^p \text{sign}(x) \text{ (componente a componente)}. \quad (12)$$

Puesto que s tiene grado relativo uno, τ_{sta} es continua, lo cual atenúa el castaño respecto de un modo deslizante de primer orden.

Suposición 1. *Existen constantes $\delta_\theta, L_\theta > 0$ tales que, sobre el conjunto compacto de operación, $\|\tilde{\Delta}\| \leq \delta_\theta$ y $\|\frac{d}{dt} \tilde{\Delta}\| \leq L_\theta$.*

La segunda condición es la restricción *esencial* del STA y suele omitirse en la literatura de control neuronal. Se explorarán dos vías para satisfacerla de manera no circular: (i) certificar L_θ a partir de la constante de Lipschitz de la red, controlada por normalización espectral y por las cotas de $\dot{q}, \ddot{q}_r$ sobre el compacto de operación; y (ii) emplear una versión de ganancia variable del STA, en la que K_1, K_2 dependen de una cota conocida en línea de la perturbación.

El análisis de estabilidad combinará la función de almacenamiento pasiva del lazo nominal con la función de Lyapunov estricta de Moreno–Osorio para el STA:

$$V(s, v) = \frac{1}{2} s^\top M(q) s + \sum_{i=1}^n \zeta_i^\top P_i \zeta_i, \quad \zeta_i = [s_i]^{1/2}, v_i]^\top, \quad (13)$$

donde el primer término aporta la estructura pasiva y el segundo la convergencia en tiempo finito. La contribución técnica consiste en establecer las condiciones sobre K_1, K_2, K_D y λ_m, λ_M bajo las cuales $\dot{V}$ es definida negativa pese al acoplamiento $M^{-1}(q)$.

4.4 Cuantificación honesta del beneficio del aprendizaje

Observación 2 (Precisión conceptual necesaria). *Bajo el STA ideal con perturbación acoplada y Lipschitz, y con ganancias correctamente dimensionadas, se tiene $s \equiv 0$ en tiempo finito y en consecuencia $e \rightarrow 0$ independientemente de la magnitud de δ_θ . Por lo tanto, **el aprendizaje no puede mejorar la precisión de seguimiento asintótica en el caso ideal, y afirmar lo contrario sería incorrecto. El beneficio del aprendizaje debe formularse en las métricas donde sí es demostrable.***

Las condiciones clásicas de ganancia son de la forma $k_2 > c_1 L_\theta$ y $k_1 > c_2 \sqrt{L_\theta}$. De aquí se derivan cuatro beneficios verificables:

- (B1) **Reducción de ganancias.** Si el aprendizaje reduce la cota de Lipschitz por un factor $\rho \in (0, 1)$, entonces k_2 se reduce por ρ y k_1 por $\sqrt{\rho}$.
- (B2) **Esfuerzo y suavidad del control.** Ganancias menores implican menor $\int \|\tau\|^2$ y menor variación total del par, es decir, menor castaño y menor desgaste del actuador.
- (B3) **Sensibilidad al ruido.** La amplificación del ruido de medición en el término $[s]^{1/2}$ escala con k_1 ; su reducción mejora el desempeño con velocidad estimada por diferenciación de encoder.
- (B4) **Precisión de deslizamiento real bajo muestreo.** En implementación discreta con periodo h , la precisión alcanzable satisface $|s| = O(k^2 h^2)$. *Éste es el mecanismo por el cual el aprendizaje sí mejora el error de seguimiento práctico, y constituye el resultado más defendible de la propuesta.*

4.5 Validación experimental

Se implementará la estrategia en una plataforma de manipulador disponible en el laboratorio, con adquisición en tiempo real y periodo de muestreo fijo. Se evaluarán cuatro configuraciones en estudio de ablación: (C1) PBC nominal; (C2) PBC + compensación aprendida; (C3) PBC + STA con ganancias de peor caso; (C4) arquitectura completa. Métricas: RMSE e ITAE del error articular, $\int \|\tau\|^2$, variación total de τ , índice de castaño, tiempo de alcance de la superficie y magnitud de las ganancias admisibles. Se incluirán escenarios de perturbación no vista en entrenamiento (carga adicional, contacto) para evaluar generalización y verificar que la degradación es acotada.

5 Contribuciones esperadas

- C1. Una parametrización de red que impone las propiedades estructurales Euler–Lagrange por construcción, con demostración de que su inclusión preserva la pasividad de salida estricta del lazo nominal.
- C2. La descomposición (9) del residuo, que delimita formalmente el alcance del aprendizaje frente al de la acción robusta.
- C3. Un certificado de Lipschitz del residuo derivado de la arquitectura de la red, que cierra de manera no circular la condición requerida por el STA.
- C4. Una relación explícita entre calidad de aproximación y ganancias mínimas admisibles, junto con la caracterización de la mejora en precisión de deslizamiento real bajo muestreo.
- C5. Validación experimental con estudio de ablación en plataforma física.

6 Plan de trabajo

Primer cuatrimestre — Fundamentos, modelado y control nominal

Revisión bibliográfica sobre control basado en pasividad, dinámica de manipuladores, aprendizaje estructurado de sistemas mecánicos y modos deslizantes de orden superior. Diseño del controlador nominal y su análisis de estabilidad. Formulación precisa de la dinámica residual (8) y de su descomposición (9). Puesta en marcha de la plataforma experimental e identificación del modelo nominal.

Entregables: modelo nominal identificado; controlador nominal funcionando en hardware; documento de estado del arte.

Segundo cuatrimestre — Aprendizaje, acción robusta y análisis

Construcción del módulo (10) y del esquema de entrenamiento libre de aceleración; diseño de trayectorias de excitación y recolección de datos. Demostración de preservación de pasividad. Diseño del STA multivariable y derivación de las condiciones de ganancia. Establecimiento de la relación $(\delta_\theta, L_\theta) \mapsto (k_1^{\min}, k_2^{\min})$. Validación en simulación de alta fidelidad.

Entregables: teoremas de estabilidad y convergencia en tiempo finito; resultados de simulación; borrador de artículo de congreso.

Tercer cuatrimestre — Validación experimental y redacción

Implementación experimental completa y estudio de ablación C1–C4. Contraste de los resultados con las predicciones teóricas, con énfasis en la relación entre error de aprendizaje, ganancias requeridas y precisión de deslizamiento real. Integración de resultados, redacción de la tesis y preparación de productos académicos.

Entregables: resultados experimentales; documento de tesis; artículo de revista sometido.

Riesgos y plan de contingencia

- *Retraso en la plataforma experimental.* Alternativa: validación en simulador de alta fidelidad con parámetros identificados y ruido de sensor realista, reservando el hardware para una demostración reducida de dos grados de libertad.

- *Certificado de Lipschitz demasiado conservador.* Alternativa: STA de ganancia variable con estimación en línea de la cota, lo que relaja la necesidad de un certificado apretado *a priori*.
- *Ruido en la estimación de velocidad.* Alternativa: diferenciador robusto exacto de Levant o filtro adaptativo, evaluando su efecto sobre el orden de precisión alcanzado.

7 Productos académicos esperados

Un artículo en congreso internacional con arbitraje (IEEE CDC, IFAC World Congress o IEEE CASE) sobre la formulación y el análisis de estabilidad, y un artículo de revista (*IEEE Transactions on Control Systems Technology*, *IEEE/ASME Transactions on Mechatronics* o *Neurocomputing*) con la validación experimental completa.

Referencias

- [1] R. Ortega, A. Loría, P. J. Nicklasson, y H. Sira-Ramírez, *Passivity-Based Control of Euler–Lagrange Systems*. Springer, 1998.
- [2] R. Ortega, A. van der Schaft, B. Maschke, y G. Escobar, “Interconnection and damping assignment passivity-based control of port-controlled Hamiltonian systems,” *Automatica*, vol. 38, no. 4, pp. 585–596, 2002.
- [3] M. W. Spong, S. Hutchinson, y M. Vidyasagar, *Robot Modeling and Control*. Wiley, 2006.
- [4] R. Kelly, V. Santibáñez, y A. Loría, *Control of Robot Manipulators in Joint Space*. Springer, 2005.
- [5] J.-J. E. Slotine y W. Li, “On the adaptive control of robot manipulators,” *The International Journal of Robotics Research*, vol. 6, no. 3, pp. 49–59, 1987.
- [6] F. L. Lewis, A. Yesildirek, y K. Liu, “Multilayer neural-net robot controller with guaranteed tracking performance,” *IEEE Transactions on Neural Networks*, vol. 7, no. 2, pp. 388–399, 1996.
- [7] R. M. Sanner y J.-J. E. Slotine, “Gaussian networks for direct adaptive control,” *IEEE Transactions on Neural Networks*, vol. 3, no. 6, pp. 837–863, 1992.
- [8] W. Yu y X. Li, “Some new results on system identification with dynamic neural networks,” *IEEE Transactions on Neural Networks*, vol. 12, no. 2, pp. 412–417, 2001.
- [9] W. Yu y X. Li, “Fuzzy identification using fuzzy neural networks with stable learning algorithms,” *IEEE Transactions on Fuzzy Systems*, vol. 12, no. 3, pp. 411–420, 2004.
- [10] W. Yu y J. Rosen, “Neural PID control of robot manipulators with application to an upper limb exoskeleton,” *IEEE Transactions on Cybernetics*, vol. 43, no. 2, pp. 673–684, 2013.
- [11] J. Reséndiz, W. Yu, y L. Fridman, “Two-stage neural observer for mechanical systems,” *IEEE Transactions on Circuits and Systems II: Express Briefs*, vol. 55, no. 10, pp. 1076–1080, 2008.
- [12] M. Raissi, P. Perdikaris, y G. E. Karniadakis, “Physics-informed neural networks,” *Journal of Computational Physics*, vol. 378, pp. 686–707, 2019.
- [13] S. Greydanus, M. Dzamba, y J. Yosinski, “Hamiltonian neural networks,” en *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [14] M. Cranmer, S. Greydanus, S. Hoyer, P. Battaglia, D. Spergel, y S. Ho, “Lagrangian neural networks,” *ICLR Workshop on Integration of Deep Neural Models and Differential Equations*, 2020.

- [15] M. Lutter, C. Ritter, y J. Peters, “Deep Lagrangian networks: Using physics as model prior for deep learning,” en *International Conference on Learning Representations (ICLR)*, 2019.
- [16] G. Shi, X. Shi, M. O’Connell, R. Yu, K. Azizzadenesheli, A. Anandkumar, Y. Yue, y S.-J. Chung, “Neural Lander: Stable drone landing control using learned dynamics,” en *IEEE International Conference on Robotics and Automation (ICRA)*, 2019.
- [17] A. Levant, “Higher-order sliding modes, differentiation and output-feedback control,” *International Journal of Control*, vol. 76, no. 9–10, pp. 924–941, 2003.
- [18] J. A. Moreno y M. Osorio, “Strict Lyapunov functions for the super-twisting algorithm,” *IEEE Transactions on Automatic Control*, vol. 57, no. 4, pp. 1035–1040, 2012.
- [19] T. González, J. A. Moreno, y L. Fridman, “Variable gain super-twisting sliding mode control,” *IEEE Transactions on Automatic Control*, vol. 57, no. 8, pp. 2100–2105, 2012.
- [20] I. Nagesh y C. Edwards, “A multivariable super-twisting sliding mode approach,” *Automatica*, vol. 50, no. 3, pp. 984–988, 2014.
- [21] V. Utkin, “On convergence time and disturbance rejection of super-twisting control,” *IEEE Transactions on Automatic Control*, vol. 58, no. 8, pp. 2013–2017, 2013.
- [22] A. Perrusquía y W. Yu, *Human-Robot Interaction Control Using Reinforcement Learning*. Wiley-IEEE Press, 2021.